

1 随机森林到最优加权随机森林的发展脉络

Leo Breiman 于2001年提出随机森林 (Random Forest, RF), 标志着集成学习进入了一个新的发展阶段。随机森林通过 Bootstrap 重采样 (Bagging) 构建大量决策树, 并在节点划分过程中随机选择部分特征, 从而同时降低模型方差和树之间的相关性。Breiman 从理论上指出, 随机森林的泛化误差随着树数量增加趋于稳定, 其性能主要取决于两个因素: 单棵树的预测能力 (Strength) 和树之间的相关性 (Correlation)。因此, 随机森林实际上是在保持个体学习器准确性的同时尽可能增加多样性。 📌 数字对象标识符 +1

然而, Breiman 提出的经典随机森林采用**均匀投票 (Uniform Averaging)**策略, 即假设森林中所有树具有相同的重要性。随着随机森林理论的发展, 越来越多研究发现, 由于 Bootstrap 抽样和随机特征选择具有随机性, 不同决策树之间存在明显的性能差异, 因此"所有树具有相同贡献"这一假设并不成立。这一认识推动了加权随机森林 (Weighted Random Forest) 的产生。

第一阶段: 经典随机森林 (Breiman RF)

代表文献:

Breiman, L. (2001). *Random Forests*. Machine Learning, 45(1), 5–32.

核心思想

随机森林由两种随机机制组成:

- Bootstrap Sampling
- Random Feature Selection

最终采用简单平均 (Regression) 或多数投票 (Classification) 得到预测结果:

$$\hat{f}(x) = \frac{1}{T} \sum_{t=1}^T f_t(x)$$

其中每棵树权重均为

$$w_i = \frac{1}{T}.$$

存在问题

虽然这种平均方式十分稳定, 但它默认所有树预测能力一致, 而事实上:

- 有些树来自更优Bootstrap样本;
- 有些树由于随机选中特征质量较高, 预测能力明显更强;
- 一部分树甚至属于"弱树"。

因此等权平均实际上没有充分利用森林内部的信息。

Breiman 当时更关注森林整体收敛性, 而没有讨论最优树权重问题。 📌 数字对象标识符

第二阶段：性能驱动的加权随机森林

约2010年前后，大量研究开始尝试赋予不同树不同权重。

代表工作包括：

- Accuracy-based Weighting
- OOB Error Weighting
- Margin-based Weighting
- Similarity Weighting
- Performance-based Weighted RF
- AUC-based Weighted RF 等。  arXiv +1

其共同思想都是：

预测能力越强的树，应获得更大的投票权重。

例如：

$$w_i \propto \frac{1}{\text{OOB Error}_i}$$

或者

$$w_i \propto \text{Accuracy}_i.$$

随后归一化：

$$\sum_i w_i = 1.$$

相比经典RF，这一阶段最大的改进是：

- 不再假设所有树完全等价；
- 引入树质量评价机制；
- 实现异质森林（Heterogeneous Forest）。



大量实验表明，在分类、医学、生物信息、故障诊断等任务中，加权随机森林通常优于经典RF。  arXiv +1

第三阶段：最优加权随机森林 (Optimal Weighted RF)

这一方向真正形成系统理论的是近年的工作。

代表文献：

Chen, Yu & Zhang (2024)

Optimal Weighted Random Forests

发表于 JMLR。 JMLR 机器学习研究期刊

这是目前随机森林权重优化领域最具代表性的工作之一。

主要贡献

作者指出：

传统Weighted RF虽然进行了加权，但权重往往来自经验规则，没有理论最优性。

因此提出：

- 1-Step Optimal Weighted RF
- 2-Step Optimal Weighted RF

二者都将森林看成一个**模型平均 (Model Averaging) **问题。

目标变为：

寻找

$$w = (w_1, \dots, w_T)$$

使

$$E[(Y - \hat{Y})^2]$$

达到最小。

最终得到的是：

理论意义上的最优组合权重 (Optimal Weight Choice)

论文进一步证明：

在一定正则条件下，

所得加权森林能够渐近达到不可实现最优模型平均 (oracle model averaging) 的风险水平，即具有渐近最优性。 JMLR 机器学习研究期刊

技术发展总结

整个随机森林优化路线可以概括为三次重要演进：

阶段	代表模型	核心思想	相比RF改进
第一阶段	Breiman RF (2001)	等权平均所有树	建立随机森林框架
第二阶段	Weighted RF	根据树性能分配权重	消除等权假设
第三阶段	Optimal Weighted RF (2024)	求解最优组合权重	建立理论最优模型平均框架

可以发现，随机森林的发展实际上经历了**"等权平均→经验加权→理论最优加权"**这一演进过程。

👉 数字对象标识符 +1

2 权重松弛理论的发展脉络

如果说最优加权随机森林解决的是"如何寻找最优权重"，那么权重松弛（Weight Relaxation）解决的是：

如何避免最优权重受到过强约束而导致性能下降。

传统模型平均通常要求：

$$w_i \geq 0, \quad \sum_i w_i = 1.$$

这是经典的凸组合约束（Convex Combination）。

虽然保证模型稳定，但限制了权重空间。

第一阶段：Ando 与 Li 提出的权重松弛思想

代表文献：

Ando, T., & Li, K.-C.

(模型平均与松弛权重理论相关工作)

其核心思想是：

传统模型平均采用标准 simplex：

$$\sum w_i = 1.$$

作者指出：

该约束并非统计最优所必需。

因此提出：

Relaxed Weight Constraint。

即允许：

- 权重不严格归一；
- 或允许权重空间进一步扩展；
- 从而降低组合偏差（Combination Bias）。

这一思想后来逐渐发展成Relaxed Model Averaging的重要理论基础。

它的贡献主要体现在：

- 降低权重约束带来的估计偏差；
- 提高模型组合自由度；
- 改善有限样本预测性能。



第二阶段：松弛权重进入统计模型平均

随后，大量统计学研究开始采用Relaxed Weight。

主要包括：

(1) Mallows Model Averaging

Mallows准则优化模型权重。

(2) Jackknife Model Averaging

Hansen 等提出JMA，将松弛权重用于预测风险最小化。

(3) Cross-validation Model Averaging

利用CV误差直接学习权重。

这一时期最大的变化是：

权重不再代表概率，而代表预测贡献。

因此，

权重允许更加灵活的优化空间。

第三阶段：松弛思想扩展到机器学习

近年来，Weight Relaxation 已逐渐进入机器学习领域。

主要包括：

(1) 集成学习

包括：

- Stacking
- Ensemble Averaging
- Weighted Ensemble
- Random Forest Weighting

越来越多研究开始采用：

- unconstrained optimization
- relaxed simplex
- sparse weighting

提高预测能力。  Wires +1

(2) 深度学习模型融合

例如：

Transformer Ensemble

多个神经网络预测时：

传统平均：

$$\frac{1}{m}$$

逐渐被：

Learning Weight

甚至

Relaxed Weight

替代。

(3) AutoML 与模型平均

现代AutoML大量采用：

- Bayesian Model Averaging
- Dynamic Ensemble
- Mixture-of-Experts

其中很多算法实际上采用的是：

Relaxed Weight Optimization。

因此，

权重松弛已经逐渐成为现代模型融合的重要思想之一。

3 权重松弛思想对随机森林的启示

目前最优加权随机森林 (Optimal Weighted RF) 虽然已经突破等权假设, 但大多数方法仍建立在传统凸约束基础上:

$$w_i \geq 0, \quad \sum_i w_i = 1.$$

因此仍存在:

- 权重搜索空间有限;
- 最优解可能位于约束边界;
- 容易产生过度稀疏或过度平均现象。

权重松弛理论提供了新的研究思路:

即:

不再把权重看作概率, 而看作最优组合系数。

从而:

扩大优化空间,

提高森林整体预测能力。

这一思想正是近年来统计模型平均与集成学习交叉发展的重要方向。

4 当前研究存在的主要瓶颈与挑战

综合近年来随机森林优化、模型平均和权重松弛等研究, 可以归纳出以下几个尚未完全解决的核心问题。

(1) 权重约束与预测性能之间的理论关系尚不清晰。 现有大多数加权随机森林仍采用非负且和为1的凸组合约束, 以保证权重具有概率解释和算法稳定性。然而, 这种约束是否在所有数据分布下都能实现最优预测仍缺乏统一理论。如何建立权重约束、偏差—方差权衡与泛化误差之间的理论联系, 是当前模型平均研究的重要开放问题。 [机器学习研究期刊 +1](#)

(2) 权重学习缺乏统一的理论框架。 目前已有的加权策略包括基于OOB误差、预测精度、AUC、交叉验证以及风险最小化等多种方法, 但不同策略分别针对不同应用场景设计, 缺少统一的优化目标和理论分析。这导致不同算法之间难以进行严格比较, 也限制了理论成果向实际应用的推广。 [arXiv +2](#)

(3) 权重优化与森林多样性的协同机制尚未充分揭示。 随机森林性能不仅依赖于单棵树的预测能力, 还依赖于树之间的相关性。已有研究多关注如何提升单棵树的重要性, 而较少考虑权重分配对森林多样性的影响。如何在“增强优势树贡献”与“保持集成多样性”之间建立动态平衡, 仍是集成学习领域的重要研究方向。 [数字对象标识符 +1](#)

(4) 松弛权重理论在随机森林中的系统研究仍然不足。 尽管权重松弛已在统计模型平均、集成预测和深度模型融合等领域得到广泛应用, 但针对随机森林的松弛权重优化研究仍较少。目前尚缺乏能够将权重松弛理论、随机森林结构特性以及模型平均理论统一起来的系统框架, 这也为未来开展“权重松弛随机森林 (Relaxed Weighted Random Forest)”相关研究提供了较大的发展空间。 [机器学习研究期刊 +1](#)

参考文献 (Representative References)

1. Breiman, L. (2001). *Random Forests*. *Machine Learning*, 45(1), 5–32.  [数字对象标识符](#)
2. Scornet, E., & Hooker, G. (2026). *Theory of Random Forests*. *Annual Review of Statistics and Its Application*, 13, 99–121.  [年鉴评论](#)
3. Chen, X., Yu, D., & Zhang, X. (2024). *Optimal Weighted Random Forests*. *Journal of Machine Learning Research*, 25, 1–81.  [机器学习研究期刊](#)
4. Shahhosseini, M., & Hu, G. (2020). *Improved Weighted Random Forest for Classification Problems*.  [arXiv](#)
5. Sagi, O., & Rokach, L. (2018). *Ensemble Learning: A Survey*. *WIREs Data Mining and Knowledge Discovery*, 8, e1249.  [Wires](#)
6. Athey, S., Tibshirani, J., & Wager, S. (2019). *Generalized Random Forests*. *Annals of Statistics*, 47(2), 1148–1178.  [gsb.stanford.edu](#)