

从等权集成到最优加权：随机森林权重优化与权重松弛理论的文献综述

2026 年 7 月

摘要

随机森林自 Breiman (2001) 提出以来，凭借其出色的灵活性和预测精度，已成为应用最广泛的集成学习方法之一。传统随机森林对所有基学习器（决策树）赋予等权重进行集成，然而由于 Bootstrap 抽样和特征选择引入的随机性，各决策树的预测性能存在显著差异。这一观察催生了加权随机森林的研究方向。与此同时，Ando 与 Li (2017) 在高维广义线性模型的模型平均框架中提出了权重松弛 (weight relaxation) 理论，通过放松权重的和为 1 约束以实现弱信号的有效组合。本文从这两个技术脉络出发，系统梳理随机森林从等权集成到最优加权的发展历程，阐述权重松弛理论的核心思想及其在集成学习领域的应用与影响，并在此基础上凝练当前该方向面临的三个核心挑战。

1 引言

随机森林 (Random Forest, RF) 由 Breiman 于 2001 年正式提出，其核心思想是通过 Bootstrap 重采样生成多棵决策树，并在节点分裂时随机选取特征子集，最终通过多数投票（分类）或平均（回归）集成各树的预测结果。这一算法兼具统计效率与计算可扩展性，已广泛应用于政策制定、商业分析、化学信息学等众多领域。

然而，传统随机森林的一个基本假设是各决策树具有同等的预测能力，因此赋予等权重。这一假设在实践中受到质疑：由于 Bootstrap 样本的随机性和特征子集的随机选择，不同决策树的预测性能往往差异显著。正如 Zhou (2012) 等学者所指出的，若个体学习器具有非相同的强度，适当的非等权平均策略可能优于简单平均。这一认识构成了加权随机森林研究的逻辑起点。

与此同时，在高维统计建模领域，模型平均方法面临另一类挑战：当候选模型数量庞大且各模型仅捕捉到微弱信号时，传统的权重约束（如权重非负且和为 1）可能限制了对弱信号的充分利用。Ando 与 Li (2017) 提出的权重松弛方法，通过放松总和约束，为这一问题提供了新的解决思路。

本文旨在系统梳理上述两条技术脉络——随机森林的加权优化与权重松弛理论——的发展历程、核心贡献与交叉影响，并在此基础上识别当前研究面临的关键瓶颈。

2 随机森林加权优化的演进脉络

2.1 经典随机森林：等权集成的基准

Breiman (2001) 的原始随机森林采用等权集成策略，即所有决策树在最终预测中具有相同的权重。这一设计的理论依据在于：通过 Bootstrap 抽样和随机特征选择引入的多样性，配合大数定律，等权平均能够有效降低方差而不引入显著偏差。Breiman 的工作奠定了随机森林作为“群体智慧”范式的基础——大量独立但多样的弱学习器通过简单平均即可获得强预测能力。

然而，等权策略的合理性依赖于一个隐含条件：各基学习器的预测性能大致相当。当这一条件不满足时，等权集成可能将过多权重赋予性能较差的树，从而损害整体预测效果。

2.2 里程碑一：基于性能的树加权随机森林

加权随机森林的早期探索主要围绕“以预测性能为依据分配树权重”这一思路展开。Li 等 (2010) 提出的 Tree Weighted Random Forest (TWRF) 是这一方向的代表性工作，其在分类任务中引入加权投票机制，根据各决策树的分类准确率赋予差异化权重。

此后，研究者发展出多种加权框架，主要包括：(1) 基于准确率的最优加权随机森林；(2) 基于 AUC (Area Under the Curve) 的最优加权随机森林；(3) 基于性能的加权随机森林；(4) 基于 Stacking 的加权随机森林模型。这些方法的共同特点是利用验证集或袋外 (Out-of-Bag, OOB) 数据评估各树的预测性能，并以此为基础确定权重。

这一阶段的贡献在于：打破了“等权”这一默认假设，初步建立了“差异化权重可提升集成性能”的经验证据。但局限也同样明显——权重通常是全局的、静态的，即对所有测试样本赋予相同的树权重，未能充分考虑不同样本区域可能适合不同的树组合。

2.3 里程碑二：最优加权随机森林——理论最优性的确立

Chen, Yu 与 Zhang (2023/2024) 在《Journal of Machine Learning Research》上发表的“Optimal Weighted Random Forests”标志着该领域的重要理论突破。该工作聚焦于回归问题，提出了两种最优加权算法：单步最优加权随机森林 (1step-WRF_{opt}) 和两步最优加权随机森林 (2steps-WRF_{opt})。

其核心贡献在于理论层面：在适当的正则性条件下，作者证明了这两种算法的渐近最优性——即其平方损失和风险渐近地等同于不可行但最优的模型平均估计量。这意味着，从渐近意义上看，该加权策略能够达到理论上限。大量真实数据集上的数值实验表明，这两种算法在大多数情况下优于等权森林及现有文献中的其他加权随机森林。

这一工作的理论价值在于将加权随机森林从启发式经验层面提升至具有理论保证的最优性框架。它为后续研究提供了一个可参照的理论基准，同时也揭示了一个关键事实：最优权重的确定本质上是一个模型平均问题。

2.4 里程碑三：自适应森林——输入依赖的动态加权

近年来，研究者开始探索更具灵活性的加权策略——权重不再全局固定，而是根据输入样本的特征动态调整。Bertsimas 与 Cui (2025) 提出的 Adaptive Forests (AF) 是该方向的代表性成果。

Adaptive Forests 的核心思想是：不同的测试样本可能适合不同的树组合，因此应当为每个输入样本量身定制一套树权重。该方法结合了两个技术组件：(1) Optimal Predictive-Policy Trees (OP²T) 框架，用于为树赋予输入依赖的非等权重；(2) 混合整数优化 (MIO)，用于动态精炼权重候选。在 20 余个真实数据集上的实验表明，AF 在二分类和多分类问题上一致优于 RF、XGBoost 及其他加权 RF 方法。

这一工作的突破性在于将加权策略从“全局静态”推进到“局部动态”，更细致地回应了不同数据区域对基学习器组合的不同需求。从方法论角度看，它标志着加权随机森林从“事后加权”（训练完成后评估树性能并赋权）向“策略性加权”（将权重视为可学习的策略）的范式转变。

2.5 其他重要进展

除上述三个里程碑外，该领域还涌现出若干值得关注的方向：

Markowitz 随机森林 (2024) 借鉴现代投资组合理论，在权重优化中同时考虑树的预测性能和树之间的多样性（通过树协方差矩阵进行风险正则化）。这一思路将集成学习中的“多样性-准确性”权衡问题与投资组合理论中的“收益-风险”权衡建立了形式上的对应。

基于决策路径的适应性加权 (2026) 观察到决策树从根到叶的拓扑模式（如类别标签翻转的位置与频率）蕴含了树可靠性的信号，并据此提出逐样本的路径自适应重加权策略。

Lassoed Forests 将随机森林的预测视为偏移项 (offset)，通过自适应 Lasso 后选择估计最优权重。

3 权重松弛理论及其在集成学习中的应用

3.1 权重松弛理论的源起与核心思想

权重松弛 (weight relaxation) 的概念由 Ando 与 Li (2017) 在《The Annals of Statistics》上正式提出。该工作的背景是高维广义线性模型中的模型平均问题——当预测变量维度随样本量增加而增长时，如何有效地组合大量候选模型。

传统模型平均方法通常对权重施加非负且总和为 1 的约束。Ando 与 Li 指出，在高维弱信号场景下，这一约束可能过于严格：当大量模型各自仅携带微弱信号时，强制权重总和为 1 可能导致权重在众多模型间过度分散，从而无法有效聚合信号。他们的核心创新在于**放松总和约束**，允许权重在一定程度上自由变化，从而更高效地捕捉和组合来自高维线性模型的微弱信号。

在理论层面，Ando 与 Li (2017) 建立了在模型误设定条件下伪真实回归参数的存在性，并推导了留一交叉验证权重选择达到渐近最优性的充分条件。这一定量刻画为权重松弛方法提供了理论支撑。

3.2 权重松弛思想的后续发展与应用

Ando 与 Li 的工作在统计建模和机器学习领域产生了持续的学术影响，其思想在多个方向上得到延伸：

模型平均理论的推广：后续研究将权重松弛思想扩展至非线性模型。例如，有学者探索将 Ando 与 Li 的方法和结果推广至非线性模型场景；另有研究在半函数部分线性模型框架下发展最优模型平均估计量。

集成学习中的权重优化：在集成学习领域，权重松弛的思想与“打破等权约束”的追求形成了自然的共鸣。尽管直接的术语借用有限，但“放松对权重的约束以提升模型组合效果”这一理念在加权随机森林、深度集成校准等工作中均有体现。例如，有研究在深度集成中联合调整权重衰减、温度缩放等超参数以优化集成性能。

稀疏驱动的加权集成：Sparsity-driven Weighted Ensemble Classifier (SDWEC) 将集成权重发现问题建模为包含数据保真项和稀疏项的成本函数。虽然未直接引用权重松弛术语，但其“通过正则化松弛权重约束”的技术思路与权重松弛理论的精神一脉相承。

因果推断中的约束松弛：在因果推断领域，重要性加权和随机森林等估计量通常隐含地限制权重非负。近期研究提出用软约束替代硬非负约束，并引入相应的超参数——这正是权重松弛思想在因果推断场景中的具体体现。

3.3 权重松弛与加权随机森林的理论交汇

值得特别指出的是，权重松弛理论与加权随机森林的最优性研究在方法论层面存在深刻的内在联系。Chen、Yu 与 Zhang (2024) 的最优加权随机森林工作，本质上是在随机森林的框架下解决一个模型平均问题——确定各决策树的最优组合权重。其渐近最优性证明所依赖的分析框架，与 Ando 与 Li (2017) 在高维模型平均中建立的理论工具具有方法论上的亲缘性。

两者共享的核心洞察在于：**传统的权重约束（等权或总和为 1）可能并非最优，适当的松弛或优化能够释放模型的组合潜力**。加权随机森林研究通过差异化树权重来打破“等权”约束，权重松弛理论通过放松总和约束来打破“归一化”约束——二者从不同角度指向了同一根本问题：权重的约束形式如何影响集成模型的预测能力。

4 当前面临的核心挑战与瓶颈

尽管加权随机森林领域已取得显著进展，但文献中仍反映出若干尚未完全解决的核心问题。

4.1 挑战一：权重优化的计算可扩展性

随着森林中决策树数量的增加，权重优化问题的规模迅速增长。对于包含 T 棵树的随机森林，全权重优化需要求解 T 维空间中的优化问题，当 T 达到数百甚至数千时，计算成本急剧上升。尽管 Chen 等（2024）提出的两步法在一定程度上缓解了这一问题，但在超大规模森林或实时预测场景中，权重优化的计算开销仍然是一个实质性瓶颈。

与此相关的是，当前多数加权方法需要额外的验证集或交叉验证来确定权重，这进一步增加了数据需求和计算负担。如何在保持权重优化收益的同时控制计算成本，是实际部署中亟待解决的问题。

4.2 挑战二：权重的可解释性与稳定性

加权随机森林在提升预测精度的同时，往往以牺牲模型的可解释性为代价。传统随机森林的一个吸引人之处在于其相对清晰的变量重要性度量。然而，当引入复杂的树权重后，变量重要性的计算和解释变得更为困难。不同加权策略下变量重要性的含义可能发生根本变化，这限制了加权随机森林在需要可解释性的应用场景（如医疗诊断、政策评估）中的采用。

此外，权重的稳定性也是一个未充分研究的问题。Bootstrap 抽样和特征选择的随机性使得不同运行批次下优化得到的权重可能差异显著，这种不稳定性是否影响模型的泛化能力，目前缺乏系统的理论分析和实证研究。

4.3 挑战三：动态加权的理论保障与泛化边界

Adaptive Forests 等动态加权方法虽然在经验上表现出色，但其理论性质远未得到充分刻画。具体而言：

- **泛化误差界的缺失**：对于输入依赖的动态加权策略，目前缺乏类似 Breiman 原始随机森林的泛化误差理论分析。
- **过拟合风险**：动态加权引入了远多于静态加权的可调参数，这增加了过拟合的风险。如何在动态加权的灵活性与统计稳定性之间取得平衡，是一个开放问题。
- **最优性条件的推广**：Chen 等（2024）的渐近最优性证明针对的是静态全局权重。当权重变为输入依赖的函数时，原有的理论框架不再适用，需要发展新的分析工具。

5 结语

从 Breiman（2001）的等权随机森林到 Chen 等（2024）的最优加权随机森林，再到 Bertsimas 与 Cui（2025）的 Adaptive Forests，随机森林的加权优化经历了“从等权到差异化”、“从启发式到理论最优”、“从全局静态到局部动态”的三次重要跃迁。与此同时，Ando 与 Li（2017）的权重松弛理论为高维模型平均中的权重约束问题提供了深刻的理论洞察，其“放松约束以捕捉弱信号”的核心思想与加权随机森林的优化追求形成了方法论上的呼应。

当前，该领域正处于从“能否提升精度”向“如何在保证理论严谨性和计算可行性的前提下实现最优加权”转变的关键阶段。计算可扩展性、可解释性与稳定性、动态加权的理论保障，构成了制约该方向进一步发展的三个核心瓶颈，也是未来研究亟需突破的方向。

References

- [1] Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5-32.
- [2] Ando, T., & Li, K.-C. (2017). A Weight-Relaxed Model Averaging Approach for High-Dimensional Generalized Linear Models. *The Annals of Statistics*, 45(6), 2654-2679.
- [3] Chen, X., Yu, D., & Zhang, X. (2024). Optimal Weighted Random Forests. *Journal of Machine Learning Research*, 25, 1-81.
- [4] Bertsimas, D., & Cui, Y. (2025). Adaptive Forests For Classification. arXiv:2510.22991.
- [5] Li, et al. (2010). Trees Weighting Random Forest (TWRf) for classification.
- [6] Zhou, Z.-H. (2012). *Ensemble Methods: Foundations and Algorithms*. CRC Press.
- [7] Biau, G., & Scornet, E. (2016). A Random Forest Guided Tour. *TEST*, 25(2), 197-227.
- [8] Winham, S. J., et al. (2013). A Weighted Random Forests Approach to Improve Predictive Performance. *Bioinformatics*, 29(23), 3015-3022.
- [9] Markowitz Random Forest: Weighting Classification and Regression Trees with Modern Portfolio Theory. (2024). *ScienceDirect*.
- [10] Decision-Path Patterns as Tree Reliability Signals: Path-based Adaptive Weighting for Random Forest Classification. (2026). arXiv.