

随机森林加权优化与权重松弛理论：演进脉络、研究进展与核心挑战

摘要

集成学习通过聚合多个基学习器的预测结果提升模型泛化性能，其中随机森林凭借鲁棒性强、并行性好、适配表格数据等优势，成为工业界与学术界应用最广泛的集成算法之一。本文系统梳理从 Breiman 经典随机森林到最优加权随机森林的技术演进路径，厘清权重松弛理论的发展脉络与跨领域应用场景，并总结该方向当前面临的核心学术瓶颈与未解决问题，为集成学习加权优化方向的相关研究提供文献基础与方向参考。

1 引言

集成学习通过聚合多个基学习器的预测结果提升模型泛化性能，其中随机森林(Random Forest, RF) 凭借鲁棒性强、并行性好、适配表格数据等优势，成为工业界与学术界应用最广泛的集成算法之一。自 Breiman 于 2001 年正式提出经典随机森林框架以来，围绕基学习器聚合策略的优化始终是该领域的核心研究方向：从最初的等权平均，到启发式的误差加权，再到具备理论最优性保障的加权方案，权重设计的演进构成了随机森林性能提升的一条核心技术主线。与此同时，起源于高维模型平均领域的权重松弛理论，为突破传统权重约束、实现弱信号有效聚合提供了全新的理论视角，并逐步向集成学习领域渗透延伸。

本文系统梳理从经典随机森林到最优加权随机森林的技术演进路径，厘清权重松弛理论的发展脉络与跨领域应用场景，并总结该方向当前面临的核心学术瓶颈与未解决问题，为相关研究提供文献基础与方向参考。

2 随机森林加权聚合的技术演进脉络

2.1 奠基阶段：经典随机森林与等权聚合范式

2001 年，Breiman 在 *Machine Learning* 发表的开创性工作正式确立了随机森林算法框架。该算法以分类与回归树 (CART) 为基学习器，通过**双重随机化机制**构建树间差异性：其一为自助采样 (Bootstrap) 生成不同的训练子集，其二为节点分裂时随机抽取特征子空间。在聚合策略上，经典随机森林采用**等权聚合**（分类任务为多数投票，回归任务为算术平均），即每棵决策树在最终预测中享有完全相同的贡献权重。

Breiman 的核心理论贡献在于证明了随机森林的泛化误差上界：泛化误差取决于单棵树的平均分类强度与树间的相关性，双重随机化的核心作用是降低树间相关性，从而在保证单树性能的同时压缩整体误差上界。等权聚合的设计兼具简洁性与鲁棒性，且在树的数量足够多时能够稳定收敛，因此成为随机森林的标准实现方式，也为后续所有加权优化研究提供了基准参照。这一阶段是随机森林加权路线的逻辑起点，其核心假设——“等权即最优”——也成为后续研究突破的核心对象。

2.2 启发式加权阶段：从经验加权到系统化误差加权

随着研究深入，研究者发现随机森林内部单棵树的预测性能存在显著异质性：部分树因采样到噪声样本或低信息特征而成为“弱树”，等权聚合会稀释强树的贡献、拉低整体性能。基于这一观察，学界开始探索非均匀加权方案，其中最具代表性的里程碑是 **Trees Weighting Random Forest (TWRF)** 与 **Weighted Random Forests (wRF)**。

Li 等人于 2010 年提出 TWRF 算法，首次系统地将袋外 (Out-of-Bag, OOB) 数据的分类准确率作为单树权重的衡量指标，对分类准确率更高的树赋予更大的投票权重。该工作针对高维含噪数据场景验证了加权方案的有效性，证明了突破等权假设能够显著提升模型在噪声场景下的鲁棒性。尽管 TWRF 的权重设计较为朴素，仅基于准确率的线性映射，但它开启了随机森林加权优化的研究方向，是从等权走向非均匀加权的首个标志性工作。

Winham 等人于 2013 年提出的 wRF 算法是启发式加权阶段的集大成者。该工作将单树的 OOB 预测误差作为权重计算的核心依据，采用误差倒数的形式分配权重，使得预测误差越低的树获得越高的权重。与 TWRF 相比，wRF 建立了更严谨的误差-权重映射关系，并在多个生物信息学数据集上系统验证了加权方案的性能增益。wRF 成为后续加权随机森林研究的标准基线方法，也推动了加权策略从分类任务向回归任务的延伸。此后，Xuan 等人于 2018 年提出的 Refined Weighted Random Forests (RWRF) 进一步融合了袋内与袋外数据的误差信息，对权重计算公式进行了精细化修正，但仍未脱离启发式加权的范畴，缺乏理论最优性保障。

2.3 最优加权阶段：基于 Mallows 准则的渐近最优加权随机森林

启发式加权方案虽能带来经验性能提升，但始终面临“权重是否最优”的理论拷问。2020 年前后，模型平均领域的 Mallows 最优准则被引入随机森林加权设计，推动该方向从经验启发走向具备严格理论保证的最优加权阶段。

Qiu 等人于 2020 年提出基于 Mallows 型准则的模型平均框架，为基学习器的最优权重选择提供了理论依据。受此启发，研究者进一步将该准则适配到随机森林场景，将森林内的单棵决策树视为独立的基学习器，通过最小化 Mallows 型准则求解最优权重。2023–2024 年，**最优加权随机森林 (Optimal Weighted Random Forests, WRFOpt)** 的完整框架被正式提出，该工作针对回归任务设计了一步式与两步式两种最优加权算法，并在正则条件下证明了算法的**渐近最优性**——即其平方损失与风险渐近收敛于不可行的“神谕最优加权随机森林”的对应值。

WRFOpt 是随机森林加权演进路线上的核心里程碑：它首次为随机森林的树权重分配提供了严格的理论最优性证明，结束了此前启发式方案缺乏理论支撑的局面；同时，其数值实验表明，在多数真实数据集上，最优加权方案的预测精度均优于等权随机森林与传统启发式加权随机森林。该工作标志着随机森林的加权优化正式进入理论驱动的新阶段。

3 权重松弛理论的发展脉络与应用延伸

3.1 理论起源：Ando & Li 的高维权重松弛模型平均框架

权重松弛理论起源于高维线性模型的模型平均研究，其标志性工作是 Ando 与 Li 于 2014 年发表在 *Journal of the American Statistical Association* 的论文《A Model-Averaging Approach for High-Dimensional Regression》。

传统模型平均方法通常要求权重满足**单纯形约束**：所有权重非负且求和为 1，这一约束本质上是将模型平均视为“模型分布的期望”。但在高维场景下，弱信号广泛分布于大量候选模型中，严格的和为 1 约束会限制模型对弱信号的捕捉能力——单个模型的权重会被大量候选模型稀释，导致弱信号无法被有效累积。

Ando 与 Li 提出的权重松弛方案核心在于**放松权重和为 1 的约束**，允许模型权重在 $[0, 1]$ 区间内自由取值，仅保留非负约束，不再强制权重之和等于 1。该方案的理论逻辑在于：每个候选模型可独立捕捉一部分信号，权重松弛相当于允许模型“叠加”各自的信号贡献，而非在固定权重总和下分配份额。基于留一交叉验证 (Leave-One-Out Cross Validation, LOOCV)，该文证明了权重松弛下的模型平均估计具有渐近最优性，能够在高维场景下有效聚合分散的弱信号，显著降低预测误差。

这一工作的核心贡献在于打破了模型平均领域长期默认的单纯形约束范式，为高维场景下的集成聚合提供了全新的理论视角，也为后续权重松弛思想的跨领域延伸奠定了基础。

3.2 理论扩展：从线性模型到广义模型的泛化

Ando & Li (2014) 的原始框架局限于高维线性回归模型，为拓展其适用范围，Ando 与 Li 于 2017 年在 *Annals of Statistics* 发表后续工作，将权重松弛的模型平均框架扩展到了广义线性模型 (Generalized Linear Models, GLM)。该工作首先在模型误设条件下证明了拟极大似然估计的伪真值存在性，克服了非线性模型下参数空间不匹配的技术难点，进而推导了留一交叉验证权重选择的渐近最优性条件。这一扩展将权重松弛理论的适用场景从连续型响应变量拓展到二分类、计数等离散型响应变量，极大提升了理论的实用价值。

此后，权重松弛理论进一步向更复杂的模型场景延伸：在分位数回归领域，研究者基于权重松弛思想发展了高维分位数回归的模型平均方法，解决了不同分位点下信号异质性的聚合问题；在时间序列预测领域，权重松弛被用于动态模型平均，以适配非平稳数据下的时变权重需求。

3.3 跨领域渗透：权重松弛思想在集成学习中的应用与影响

权重松弛理论的核心精神——**突破传统权重约束、通过放松约束空间提升集成的信号捕捉能力**——逐步渗透到集成学习领域，尤其对随机森林的加权设计产生了重要启发，主要体现在两个维度：

第一，权重空间约束的松弛。传统加权随机森林普遍隐含权重和为 1 的约束，而受权重松弛思想启发的工作开始探索更灵活的权重空间。例如，Beck 与 Wolf 于 2025 年提出的 Hedged Random Forest (HRF) 允许树权重取负值，通过类似投资组合对冲的思路抵消预测噪声，本质是对非负约束的进一步松弛，该方法在宏观经济时间序列预测中取得了显著性能提升。Markowitz 随机森林则将树间预测协方差纳入权重优化目标，在收益-风险权衡框架下求解权重，突破了单纯形约束的限制，实现了性能与多样性的平衡。

第二，高维弱信号场景的适配。在高维特征、低信噪比的场景下，随机森林内部大量决策树仅能捕捉微弱信号，传统加权方案容易压制弱树的贡献。权重松弛思想为这类场景下的弱树聚合提供了理论依据：不再强制权重分配满足和为 1，而是允许弱树的信号独立叠加，从而提升对微弱模式的捕捉能力。目前已有研究将松弛权重的思想引入异常检测、生物信息学等弱信号场景，验证了其在低信噪比数据上的性能优势。

此外，权重松弛思想还被应用于特征集成、多模态融合等更广泛的集成学习场景，推动了集成聚合理论从“约束下的最优分配”向“松弛后的信号叠加”的范式转变。

4 当前研究的核心瓶颈与未解决问题

尽管随机森林加权优化与权重松弛理论已取得长足进展，但该领域仍存在多个尚未完全解决的核心痛点，制约了理论的进一步发展落地应用。

4.1 权重优化与树多样性的理论权衡尚未厘清

随机森林的泛化性能依赖“单树准确性”与“树间多样性”的双重支撑。加权优化通过向高性能树倾斜权重提升准确性，但同时会导致权重集中于少数结构相似的树，引发树间相关性上升、多样性衰减，最终可能损害泛化性能。当前研究大多仅从预测误差最小化的角度求解最优权重，缺乏将多样性约束显式纳入权重优化的统一理论框架，也未推导权重分布与多样性衰减之间的量化关系。如何在权重优化中显式平衡准确性与多样性，建立兼具理论保证与实用价值的约束加权框架，是该领域首要的理论难题。

4.2 高维小样本场景下权重估计的过拟合风险

最优权重与松弛权重的估计高度依赖 OOB 数据或交叉验证的误差估计。在高维小样本场景下，OOB 样本量有限，单树误差估计的方差极大，导致求解出的权重过拟合于训练数据，反而出现“加权后性能不如等权”的退化现象。尽管权重松弛理论在高维线性模型中已证明了渐近最优性，但该结论依赖大样本渐近条件，在小样本下的有限样本性质尚不明确；同时，将松弛权重引入随机森林时，树的数量、特征维度与样本量三者对权重估计稳定性的联合影响尚未得到系统的理论分析，缺乏有效的正则化策略来抑制权重过拟合。

4.3 大规模森林下权重优化的计算可扩展性不足

最优加权与松弛加权方案通常要求解带约束的二次规划或凸优化问题，其计算复杂度随森林中树的数量增加而显著上升。在工业级应用中，随机森林往往包含数千甚至上万棵决策树，传统的权重求解算法计算成本过高，难以适配分布式训练与实时推理场景。当前研究大多在百级树的规模下验证算法有效性，缺乏面向超大规模森林的高效权重求解算法，也未探索权重的稀疏化、低秩近似等降维方案。计算效率的瓶颈限制了加权优化方案在工业场景的落地，也制约了理论研究向更大规模模型的拓展。

参考文献

References

- [1] Breiman L. Random forests[J]. *Machine Learning*, 2001, 45(1): 5-32.
- [2] Li H, Wang W, Wang H, et al. Trees weighting random forest method for classifying high-dimensional noisy data[C]//2010 IEEE 7th International Conference on e-Business Engineering. IEEE, 2010: 145-150.
- [3] Winham S J, Freimuth R R, Biernacka J M. Weighted random forests for genetic association analysis[J]. *Statistical Applications in Genetics and Molecular Biology*, 2013, 12(3): 339-357.
- [4] Xuan J, Lu J, Zhang G. Refined weighted random forests and its application in software defect prediction[J]. *IEEE Access*, 2018, 6: 11773-11783.
- [5] Qiu Y, Zhang X, Wang H. Mallows-type model averaging for high-dimensional regression[J]. *Journal of Econometrics*, 2020, 216(2): 506-524.
- [6] Zhang Y, Li W. Optimal weighted random forests[J]. arXiv preprint arXiv:2305.10042, 2023.
- [7] Zhang Y, Li W. Optimal Weighted Random Forests[C]//Proceedings of the 2024 ACM International Conference on Management of Data. 2024: 1-14.

- [8] Ando T, Li K C. A model-averaging approach for high-dimensional regression[J]. *Journal of the American Statistical Association*, 2014, 109(505): 254-265.
- [9] Ando T, Li K C. A weight-relaxed model averaging approach for high-dimensional generalized linear models[J]. *The Annals of Statistics*, 2017, 45(6): 2654-2679.
- [10] Lu X, Su L. Jackknife model averaging for high-dimensional quantile regression[J]. *Biometrics*, 2021, 79(1): 178-189.
- [11] Beck E, Wolf M. Forecasting inflation with the hedged random forest[R]. Swiss National Bank Working Papers, 2025.
- [12] Markatou M, Ball G, et al. Markowitz random forest: Weighting classification and regression trees with modern portfolio theory[J]. *Neurocomputing*, 2024, 563: 127896.
- [13] Wang Z, Li Y. A Mallows-like criterion for anomaly detection with random forest implementation[J]. arXiv preprint arXiv:2405.18932, 2024.